

Forecasting

Proyecto Final

MUDS 2025
Ivan Betriu Kahlenberg
Marc Fort Garcia

1. Explicación de los datos, su origen e interés de su estudio.


En el presente estudio adaptamos el Índice de Precios de Vivienda (IPV) para centrarnos exclusivamente en viviendas nuevas en Cataluña, que mide la evolución de los precios de compraventa de viviendas de precio libre a lo largo del tiempo, utilizando para ello los datos de las escrituras públicas que registra el Consejo General del Notariado. En concreto, el índice se construye agrupando todas las viviendas escrituradas en el periodo de referencia según características homogéneas. A partir de estas ponderaciones se calcula la variación media de precio para cada grupo, y luego se agregan esas variaciones en función de los pesos correspondientes, obteniendo así una cifra única que refleja la tasa de cambio global de los precios de la vivienda. De este modo, el IPV ofrece una medida homogénea y periódica de cómo fluctúa el valor de la vivienda nueva en Cataluña, sin incluir el IVA en los precios de obra nueva y tomando como referencia únicamente las transacciones reales registradas en el territorio. El periodo de referencia en este caso es 2007.

2. Análisis exploratorio de los datos.

El dataset base contiene seis columnas, Total Nacional, Comunidad, Tipo de vivienda, índice y tasas, y los dos columnas en que nos centraremos que son periodo y Total. En este caso los periodos son trimestrales, o frecuencia de cuatro anual. Se escogió el 80% de los periodos como periodo muestral (58 observaciones) y el 20% para el extramuestral (14 observaciones)

Se visualizaron los datos donde se aprecia la caída del valor debida a la crisis del 2008 y como se recupera ya en siguientes periodos. Visualizandose dos ciclos diferenciados. Y tendencias estables a largo plazo. No se aprecia una estacionalidad marcada.

Índice de precios de la vivienda nueva en Cataluña



Posteriormente se evalúa la estacionariedad con el test aumentado de Dicker Fuller

Augmented Dickey-Fuller Test

```
data: df_muestral
Dickey-Fuller = -1.1109, Lag order = 3, p-value = 0.913
alternative hypothesis: stationary
```

En este caso, el p-value supera el 0.05, por lo que no se puede aceptar la hipótesis alternativa de estacionariedad, concluyendo que la serie no es estacionaria.


3. Aplicación de modelos deterministas.

Dentro de los métodos deterministas que se adecuan a una serie con tendencia y sin estacionalidad hay dos técnicas principales: Método de tendencia lineal y método de alisado exponencial lineal de Holt.

La primera técnica, el método de tendencia lineal, al ajustarse a una serie que presenta dos ciclos opuestos, tenderá a dibujar una recta que conecta de forma intermedia ambos movimientos.

La segunda técnica, el método de alisado exponencial lineal de Holt, a partir de la descomposición aditiva de la serie, extrae el componente de tendencia y lo proyecta para obtener su evolución futura. A continuación se muestran los resultados.

Pronóstico Holt lineal y Valores Reales



MSE: 215.716
RMSE: 14.687
MAE: 12.193

Se aprecia una predicción bastante precisa con un MSE de 264, la línea de pronóstico se asemeja a la de la serie mostrada anteriormente.

4. Aplicación de modelos estocásticos.

En cuanto a la aplicación de modelos estocásticos, se ha optado por comparar 2 métodos: Se implementarán tanto un modelo ARIMA como un modelo ETS (suavizado exponencial en forma de espacio-estado).


Para el modelo ARIMA se ha utilizado la función “auto.arima” para ajustar el modelo automáticamente y el resultado fue el siguiente:

```
Series: serie_ts
ARIMA(0,2,1)

Coefficients:
      ma1
    -0.7739
s.e.    0.0903

sigma^2 = 11.42: log likelihood = -147.6
AIC=299.2  AICc=299.43  BIC=303.25

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE
Training set -0.1011314 3.290824 2.56718 0.04060936 2.161138 0.284479
      ACF1
Training set -0.07843906
```



Podemos observar que se ajustó un modelo ARIMA (0,2,1) con bastantes buenos resultados.

Para el modelo ETS se ha utilizado la función “ets” con unos resultados parecidos al de ARIMA:

```

Call:
ets(y = serie_ts)

Smoothing parameters:
  alpha = 0.8373
  beta  = 0.276


Initial states:
  l = 141.4675
  b = 1.4471

sigma: 3.3731

      AIC      AICc      BIC
382.3969 383.5507 392.6991

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE
Training set 0.009943376 3.254688 2.530019 0.1091906 2.133714 0.280361
      ACF1
Training set -0.006719061

```



5. Aplicación de modelos avanzados de predicción.

Para el modelo avanzado se optó por implementar un modelo XGBoost. Como este modelo no está diseñado para trabajar con series temporales, el primer paso fué crear una matriz de lags ($n = 4$) para poder representar la información de los valores anteriores. Posteriormente se realizó una partición train/test para entrenar el modelo


6. Discusión de los resultados obtenidos en cada método y su uso utilidad en una situación real.

Los resultados de los modelos fueron los siguientes:


	HOLT LINEAL	ARIMA	ETS	XGBOOST
RMSE	14.6873	12.2359	14.6873	44.4124
MAE	12.1933	10.0250	12.1933	41.3447
MSE	215.7172	149.7190	215.7172	1972.4642

A continuación se adjuntan los gráficos de las predicciones vs los valores reales:


HOLT:




ARIMA:



ETS:



XGBoost:



Estos gráficos corroboran lo que ya hemos visto numéricamente: Holt, ETS y ARIMA tienen performances muy parecidas, con ARIMA siendo ligeramente superior mientras que XGBoost tiene problemas a la hora de predecir. En un use case real, se optaría por uno de

los modelos más simples no solo por su mayor rendimiento sino por su menor coste computacional.